

稀疏内容页

EDGE-NULL-007

第 1 页故意完全空白。本页用于确认解析器能保留页码边界，不把空白页报告为文件损坏。

密集内容页：分页与页脚边界

本页不包含真实业务数据。它用于检查多页 PDF 中的页顺序、上下边界、表格提取与长文本分块。

A | 应当被检索的关键句

唯一边界句：“空白页不是错误；稀疏页不是无文件；密集页不应覆盖前两页的页级状态。”

B | 页级预期

页码	内容状态	预期提取
1	完全空白	文本长度为 0；页面仍存在。
2	稀疏	应命中标记 EDGE-NULL-007 与一段说明。
3	密集	应保留标题、关键句、表格与底部校验句。

C | 长文本块

解析器在分块时需保留语义边界。如果采用约定字符数切分，应当留有适度重叠，但不应把空白页与下一页的内容合并后误报为空白页本身的文本。结果展示应该明确区分“文件已上传”、“文件已解析”、“某一页无可提取文本”与“检索未命中”四种不同状态。

专业的错误信息不应说“PDF 不可用”，而应说明页数、已提取字符数、空白页编号和是否需要 OCR。这样才能帮助用户区分上传故障、解析能力限制和查询不够具体。

D | 底部校验句

底部边界标记：BOTTOM-ANCHOR-031。若渲染后该行被页脚遮挡、裁切或重叠，则视觉验收失败。